

# Sujet : Est-il possible de prédire la réussite d'un apprenant en analysant ses traces numériques au sein de la plateforme ARCHE ?

Jean-Claude Faber

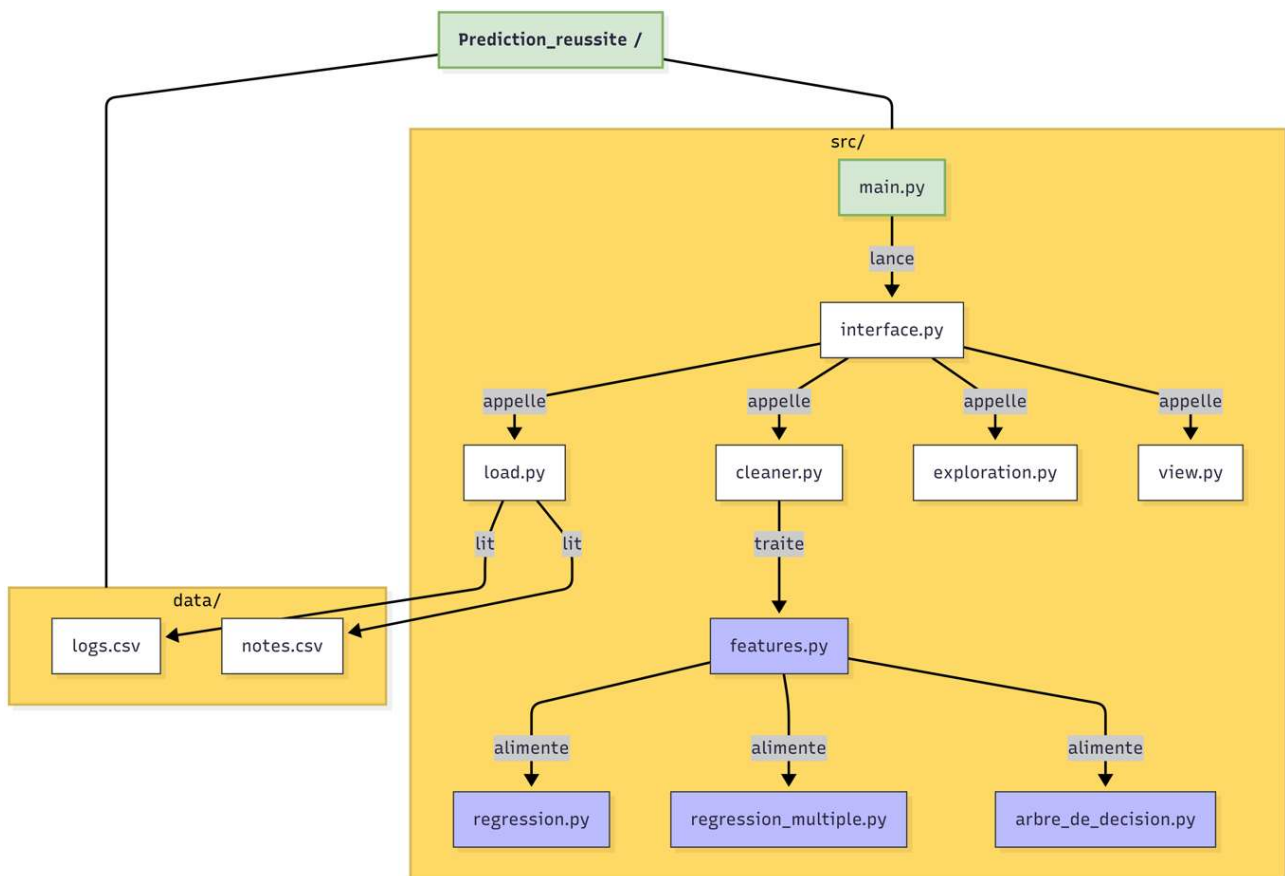
## Table des matières

1. Structure du projet.....	1
2. Détermination de l'algorithme principal :.....	2
3. Règle à respecter pour chaque blocs :.....	2
4. Fichier de chargement des datas (load.py) :.....	3
5. Fichier de nettoyage des données (cleaner.py) :.....	5
6. Fichier des paramètres à suivre (features.py) :.....	8
7. Fichier d'exploration des données (exploration.py) :.....	12
8. Fichier de régression unitaire des données (regression.py) :.....	14
9. Fichier de regression multiple (regression_multiple.py) :.....	16
10. Arbre de décision (arbre_de decision;py) :.....	18
11. Interface (interface.py) :.....	21
12. Interface (main.py) :.....	25
13. Conclusion :.....	27

## 1. Structure du projet

- Détermination de l'algorithme principal
- Règle à respecter pour chaque bloc de programmation
- Description de chaque chaque bloc de programmation
- Conclusion

## 2. Détermination de l'algorithme principal :



## 3. Règle à respecter pour chaque blocs :

Gestion des erreurs :

Chaque bloque dont c'est nécessaire va renvoyer le couple `(None, None)` au bloc suivant pour avoir une propagation des erreurs .

## 4. Fichier de chargement des datas (load.py) :

Installation du package pandas qui est nécessaire pour la lecture des fichiers csv

- package pandas 3.0.0

Le module load.py assure l'acquisition sécurisée des données en localisant les fichiers logs.csv et notes.csv dans le répertoire dédié. Il utilise la bibliothèque Pandas pour convertir ces ressources brutes en structures de données exploitables (DataFrames). Une gestion d'erreurs est intégrée pour détecter les fichiers manquants, vides ou verrouillés par un autre programme. Enfin, il confirme le succès de l'opération en affichant le volume de lignes lues, ce qui permet de garantir l'intégrité de la base de travail pour les étapes suivantes.

### fichier load.py :

```
import pandas as pd
import os
```

```
# chemin vers les fichiers
```

```
def charger_donnees():
    chemin_logs = "../data/logs.csv"
    chemin_notes = "../data/notes.csv"
```

```
# message d'erreur si on ne trouve pas les fichiers
```

```
if not os.path.exists(chemin_logs) or not os.path.exists(chemin_notes):
    if not os.path.exists(chemin_logs):
        print("ERREUR : Le fichier des logs est manquant")
        print("Vérifie que tu as bien copié les fichiers dans data")
    if not os.path.exists(chemin_notes):
        print("ERREUR : Le fichier des notes est manquant")
        print("Vérifie que tu as bien copié les fichiers dans data")
    return None, None
```

```
else:
```

```
    try :#lecture des fichiers
```

```
        df_logs = pd.read_csv(chemin_logs)
        df_notes = pd.read_csv(chemin_notes)
        print("Les données ont été chargées avec succès!")
        print(f"Fichier logs : {len(df_logs)} lignes lues")
        print(f"Fichier notes : {len(df_notes)} lignes lues")
```

```
        return df_logs, df_notes
```

```
except FileNotFoundError:
```

```
    print("ERREUR : Le fichier est introuvable vérifie si le dossier data est présent?")
    return None, None
```

```
except pd.errors.EmptyDataError:
```

```
    print("ERREUR : Le fichier CSV est vide ! ajoute le fichier")
    return None, None
```

```
except PermissionError:
```

```
    print("ERREUR : Le fichier est déjà ouvert dans un autre programme merci de le fermer pour que cela fonctionne")
    return None, None
```

```
except Exception as erreur_inconnue:
```

```
    print(f"ERREUR IMPRÉVUE lors du chargement des données: {erreur_inconnue}")
```

```

        return None, None

if __name__ == "__main__":
    charger_donnees()

```

## Gestion des erreurs de load.py :




La suppression du fichier notes.csv et logs.csv donne bien :

```

C:\Users\Etudiant\PycharmProjects\Prediction_reussite\.venv\Scripts\python.exe C:\Users\Etudiant\PycharmProjects\Prediction_reussite\src\load.py
ERREUR : Le fichier des logs est manquant
Vérifie que tu as bien copié les fichiers dans data
ERREUR : Le fichier des notes est manquant
Vérifie que tu as bien copié les fichiers dans data

Process finished with exit code 0

```



La suppression du dossier notes.csv donne bien :

```

C:\Users\Etudiant\PycharmProjects\Prediction_reussite\.venv\Scripts\python.exe C:\Users\Etudiant\PycharmProjects\Prediction_reussite\src\load.py
ERREUR : Le fichier des notes est manquant
Vérifie que tu as bien copié les fichiers dans data

Process finished with exit code 0

```



La suppression du dossier logs.csv donne bien :

```

C:\Users\Etudiant\PycharmProjects\Prediction_reussite\.venv\Scripts\python.exe C:\Users\Etudiant\PycharmProjects\Prediction_reussite\src\load.py
ERREUR : Le fichier des logs est manquant
Vérifie que tu as bien copié les fichiers dans data

Process finished with exit code 0

```

J'ai vidé le fichier notes j'obtiens bien :

```

C:\Users\Etudiant\PycharmProjects\Prediction_reussite\.venv\Scripts\python.exe C:\Users\Etudiant\PycharmProjects\Prediction_reussite\src\load.py
ERREUR : Le fichier CSV est vide ! ajoute le fichier

Process finished with exit code 0

```

j'ai ouvert en lecture le fichier notes.csv avec Windows PowerShell :

```

PSC\Users\Etudiant>$file=[System.IO.File]::Open("C:\Users\Etudiant\PycharmProjects\Prediction_
reussite\data\notes.csv", "Open", "Read", "None")

```

j'obtiens :

```

C:\Users\Etudiant\PycharmProjects\Prediction_reussite\.venv\Scripts\python.exe C:\Users\Etudiant\PycharmProjects\Prediction_reussite\src\load.py
ERREUR : Le fichier est déjà ouvert dans un autre programme merci de le fermer pour que cela fonctionne

Process finished with exit code 0

```

## 5. Fichier de nettoyage des données (cleaner.py) :

Source : [https://scikit-learn.org/stable/modules/model\\_evaluation.html#accuracy-score](https://scikit-learn.org/stable/modules/model_evaluation.html#accuracy-score)

Le module cleaner.py permet d'éliminer les doublons dans le fichier des notes et supprimer les logs d'heure invalides. Il réalise ensuite une jointure pour conserver les étudiants inscrits dans le fichier des notes. Cette étape de nettoyage est sécurisée par un try ... except qui interceptent les erreurs imprévues sans interrompre l'application. Des messages de validation confirment en temps réel le nombre d'étudiants traités.

### fichier load.py :

```
import pandas as pd
```

```
# récupération des fichiers provenant de load
```

```
def nettoyage_donnees(df_logs, df_notes) :
```

```
# si le chargement a échoué un message d'erreur apparaît
```

```
if df_logs is None or df_notes is None :
```

```
    print("il n'est pas possible de nettoyer les données car il y a un souci pour la lecture des fichiers logs.csv et notes.csv")
```

```
    return None, None
```

```
try :
```

```
# on vérifie si il n'y a pas de duplica dans notes.csv
```

```
nb_avant = len(df_notes)
```

```
df_notes_clean = df_notes.drop_duplicates()
```

```
if (nb_avant - len(df_notes_clean)) == 0:
```

```
    print(f"le nombre de doublon dans notes.csv est de {nb_avant - len(df_notes_clean)} ")
```

```
    print("il n'y a donc pas de doublon")
```

```
elif (nb_avant - len(df_notes_clean)) > 0:
```

```
    print(f"le nombre de doublon dans notes.csv est de {nb_avant - len(df_notes_clean)} ")
```

```
# Vérification finale des doublons
```

```
nb_doublons_final = df_notes_clean.duplicated().sum()
```

```
print(f"VÉRIFICATION : Nombre de doublons restants dans notes : {nb_doublons_final} ")
```

```
print("les doublons ont été supprimés")
```

```
# conversion des dates avec coerse si une case n'est pas convertie correctement une case vide sera mise en place
```

```
df_logs['heure'] = pd.to_datetime(df_logs['heure'], errors='coerce')
```

```
nb_erreurs_date = df_logs['heure'].isna().sum()
```

```
if nb_erreurs_date == 0:
```

```
    print("Toutes les dates ont été converties correctement")
```

```
elif nb_erreurs_date > 0:
```

```
    print(f"le nombre de date non converties est de {nb_erreurs_date} ")
```

```
# subset cible uniquement la case heure pour les suppressions
```

```
df_logs = df_logs.dropna(subset=['heure'])
```

```
# Vérification finale des dates
```

```
nb_erreurs_date_final = df_logs['heure'].isna().sum()
```

```
print(f"VÉRIFICATION : Nombre de dates non converties (NaT) restantes : {nb_erreurs_date_final} ")
```

```
print(f"les {nb_erreurs_date} dates non converties ont été supprimées ")
```

```
# comparaison des etudiants dans logs et notes
```

```
nb_etudiants_notes = df_notes_clean['pseudo'].nunique()
```

```
nb_etudiants_logs_avant = df_logs['pseudo'].nunique()
```

```
print("Comparaison avant nettoyage")
```

```
print(f"Étudiants dans le fichier NOTES : {nb_etudiants_notes} ")
```

```
print(f"Étudiants dans le fichier LOGS : {nb_etudiants_logs_avant} ")
```

```

# On regarde les étudiants présent dans logs (étudiant unique)
etudiants_avec_notes = df_notes_clean['pseudo'].unique()

# On ne garde que les clics des étudiants qui sont dans le fichier notes
df_logs_clean = df_logs[df_logs['pseudo'].isin(etudiants_avec_notes)]

# Comparaison apres nettoyage
nb_logs_final = df_logs_clean['pseudo'].nunique()

print("Comparaison après nettoyage")
print(f"Étudiants dans le fichier NOTES : {nb_etudiants_notes} ")
print(f"Étudiants dans le fichier LOGS : {nb_logs_final} ")
return df_logs_clean, df_notes_clean

except Exception as erreur_inconnue:
    print(f"ERREUR IMPRÉVUE lors du nettoyage des données : {erreur_inconnue} ")
    return None, None

if __name__ == "__main__":
    import pandas as pd

    # valeur incorrecte pour test logs et notes
    data_logstest = {
        'pseudo': ['436', '841', '436', '18'],
        'heure': ['2024-07-24 09:48:08', '2024-07-24 09:48:08', 'HEURE', '2024-08-24 09:48:08'], # date invalide
        'contexte': ['Cours', 'Cours', 'Cours', 'Cours']
    }

    data_notestest = {'pseudo': ['436', '436', '841'], 'note': [12, 12, 15]}

    # conversion en dataframe
    df_logs_test = pd.DataFrame(data_logstest)
    df_notes_test = pd.DataFrame(data_notestest)

    # test unitaire
    nettoyage_donnees(df_logs_test, df_notes_test)

```

## **Gestion des erreurs de cleaner.py :**

avec `if __name__ == "__main__":`

et les fichiers de test de data avec erreur

```

data_logstest = {
    'pseudo': ['436', '841', '436', '18'], # présence du doublon 436
    'heure': ['2024-07-24 09:48:08', '2024-07-24 09:48:08', 'HEURE', '2024-08-24 09:48:08'], # date invalide
    'contexte': ['Cours', 'Cours', 'Cours', 'Cours']
}

data_notestest = {'pseudo': ['436', '436', '841'], 'note': [12, 12, 15]} # Etudiant 18 non présent dans data_notetest

```

### Test des Doublons (Fichier Notes) :

Le doublon 436 est bien supprimé

```
C:\Users\Etudiant\PycharmProjects\Prediction_reussite\.venv\Scripts\python.exe C:\Users\Etudiant\PycharmProjects\Prediction_reussite\src\cleaner.py
Le nombre de doublon dans notes.csv est de 1
VÉRIFICATION : Nombre de doublons restants dans notes : 0
Les doublons ont été supprimés
Le nombre de date non converties est de 1
VÉRIFICATION : Nombre de dates non converties (NaT) restantes : 0
Les 1 dates non converties ont été supprimées
Comparaison avant nettoyage
Étudiants dans le fichier NOTES : 2
Étudiants dans le fichier LOGS : 3
Comparaison après nettoyage
Étudiants dans le fichier NOTES : 2
Étudiants dans le fichier LOGS : 2

Process finished with exit code 0
```

### Test des Dates Invalides (Fichier Logs) :

Le format de date invalide a bien été détecté et supprimé

```
C:\Users\Etudiant\PycharmProjects\Prediction_reussite\.venv\Scripts\python.exe C:\Users\Etudiant\PycharmProjects\Prediction_reussite\src\cleaner.py
Le nombre de doublon dans notes.csv est de 1
VÉRIFICATION : Nombre de doublons restants dans notes : 0
Les doublons ont été supprimés
Le nombre de date non converties est de 1
VÉRIFICATION : Nombre de dates non converties (NaT) restantes : 0
Les 1 dates non converties ont été supprimées
Comparaison avant nettoyage
Étudiants dans le fichier NOTES : 2
Étudiants dans le fichier LOGS : 3
Comparaison après nettoyage
Étudiants dans le fichier NOTES : 2
Étudiants dans le fichier LOGS : 2

Process finished with exit code 0
```

### Test de Cohérence (Étudiants Inconnus) :

L'étudiant 18 est présent dans les logs et n'est pas présent dans les notes il doit donc être supprimé ce qui est le cas :

```
C:\Users\Etudiant\PycharmProjects\Prediction_reussite\.venv\Scripts\python.exe C:\Users\Etudiant\PycharmProjects\Prediction_reussite\src\cleaner.py
Le nombre de doublon dans notes.csv est de 1
VÉRIFICATION : Nombre de doublons restants dans notes : 0
Les doublons ont été supprimés
Le nombre de date non converties est de 1
VÉRIFICATION : Nombre de dates non converties (NaT) restantes : 0
Les 1 dates non converties ont été supprimées
Comparaison avant nettoyage
Étudiants dans le fichier NOTES : 2
Étudiants dans le fichier LOGS : 3
Comparaison après nettoyage
Étudiants dans le fichier NOTES : 2
Étudiants dans le fichier LOGS : 2

Process finished with exit code 0
```

## **6. Fichier des paramètres à suivre (features.py) :**

Description des paramètres de suivi :

### **1<sup>er</sup> Volume d'activités (nombre total d'actions)**

Cela permet de déterminer la présence numérique de l'étudiant sur la plateforme.

Un volume faible peut être un signe de décrochage scolaire.

### **2<sup>ème</sup> Temps d'activité réel (Intervalle de 5 minutes)**

Somme des durées séparant deux clics consécutifs, à condition que cet intervalle soit inférieur à 5 min.

Cela permet d'estimer le temps de travail effectif et cela filtre les périodes d'inactivité.

### **3<sup>ème</sup> Régularité (nombre de jour actif)**

Décompte du nombre de jours uniques où au moins une action a été enregistrée.

Cela permet de visualiser la répartition de l'apprentissage.

### **4<sup>ème</sup> diversité des ressources consultées :**

Nombre de catégories de ressources différentes consultées.

Permet de visualiser l'intérêt de l'étudiant.

### **5<sup>ème</sup> Etendue de l'exploration (contexte unique consulté) :**

Permet de visualiser la couverture du programme

### **6<sup>ème</sup> Performance (nombre de tests effectués) :**

Permet de compter le nombre de test réalisé en auto-évaluation

Le module features.py commence par vérifier la validité des données pour assurer un arrêt propre et sécurisé en cas de fichiers manquants, Il extrait des indicateurs clés de l'engagement des étudiants.

Les paramètres de suivi sont ensuite fusionnées avec le fichier des notes, en remplaçant les valeurs vides par des zéros pour les étudiants n'ayant jamais été sur la plateforme.

Une vérification du tableau paramètre notes est affiché pour vérification ceci est également fait pour les étudiant qui ne se sont pas connecté sur ARCHE

```
import pandas as pd
from cleaner import nettoyage_donnees
from load import charger_donnees

def calculer_indicateurs(df_logs_clean, df_notes_clean):
    if df_logs_clean is None or df_notes_clean is None:
        print("\n[!] ERREUR (features.py) : Les données nettoyées sont absentes (None).")
        print("    -> Le calcul des indicateurs ne peut pas être effectué.")
        return None

    print("Création du tableau avec les indicateurs de suivi")

    # -----
    # 1. VOLUME : Nombre total de clics
    # -----
    # Création d'une colonne de comptage de clic par étudiant
    comptage_vol = df_logs_clean['pseudo'].value_counts()
    df_volume = pd.DataFrame({'pseudo': comptage_vol.index, 'nb_clics': comptage_vol.values})

    # -----
```



```

# 2. RÉGULARITÉ : Nombre de jours différents de connexion
# -----
# Création d'une colonne du nombre de jours différents de connexion par étudiant
df_logs_clean['jour'] = df_logs_clean['heure'].dt.date
comptage_reg = df_logs_clean.groupby('pseudo')['jour'].nunique()
df_regularity = pd.DataFrame({'pseudo': comptage_reg.index, 'nb_jours': comptage_reg.values})

# -----
# 3. DIVERSITÉ : Nombre d'outils différents (Test, Fichier...)
# -----
# Création d'une colonne du nombre d'outils différents utilisé par étudiant
comptage_div = df_logs_clean.groupby('pseudo')['composant'].nunique()
df_diversite = pd.DataFrame({'pseudo': comptage_div.index, 'nb_composants': comptage_div.values})

# -----
# 4. ÉTENDUE : Nombre de ressources/chapitres consultés
# -----
# Création du nombre de ressources/chapitres consultés par étudiant
comptage_ete = df_logs_clean.groupby('pseudo')['contexte'].nunique()
df_etendue = pd.DataFrame({'pseudo': comptage_ete.index, 'nb_contextes': comptage_ete.values})

# -----
# 5. TEMPS : Somme des sessions (Règle des 300 secondes)
# -----
# les actions par élève sont rangées par ordre chronologique
df_logs_clean = df_logs_clean.sort_values(by=['pseudo', 'heure'])

# calcule du temps écoulé (en secondes) entre deux clics consécutifs
df_logs_clean['ecart'] = df_logs_clean.groupby('pseudo')['heure'].diff().dt.total_seconds()

# les écarts < 300s sont gardés (on ignore les pauses de plus de 300 s (5 min))
petits_ecarts = df_logs_clean[df_logs_clean['ecart'] < 300]

# On additionne les petits écarts pour chaque élève
somme_tps = petits_ecarts.groupby('pseudo')['ecart'].sum()

# Création du tableau de synthèse
df_temps = pd.DataFrame({'pseudo': somme_tps.index, 'temps_total_sec': somme_tps.values})

# -----
# 6. PERFORMANCE : Nombre d'évaluations (tests)
# -----
# les lignes où l'activité est un 'test' sont captées
df_logs_tests = df_logs_clean[df_logs_clean['composant'] == 'Test']

# Comptage des lignes par étudiant
comptage_tests = df_logs_tests['pseudo'].value_counts()

df_tests = pd.DataFrame({'pseudo': comptage_tests.index, 'nb_tests': comptage_tests.values})

# -----
# 7. FUSION FINALE (injection des zéros)
# -----
# On part du tableau des NOTES (les 99 étudiants officiels)
df_final = df_notes_clean.copy()

# On fusionne chaque petit tableau un par un avec aussi les 4 qui n'ont pas de clics
df_final = pd.merge(df_final, df_volume, on='pseudo', how='left')
df_final = pd.merge(df_final, df_regularity, on='pseudo', how='left')
df_final = pd.merge(df_final, df_diversite, on='pseudo', how='left')

```

```

df_final = pd.merge(df_final, df_etendue, on='pseudo', how='left')
df_final = pd.merge(df_final, df_temps, on='pseudo', how='left')
df_final = pd.merge(df_final, df_tests, on='pseudo', how='left')

# remplacement de tous les vides (NaN) par 0 pour ceux qui ne se sont pas connectés à ARCHE
df_final = df_final.fillna(0)

print(f"L'étude va porter sur {len(df_final)} étudiants ")

# Vérifications finales
print("VÉRIFICATION DU TABLEAU FINAL")
print(f"Nombre total de lignes : {len(df_final)} ")
print("\nAperçu des 5 premières lignes :")
print(df_final.head())

# Vérification de ceux qui ne se sont pas connectés sur ARCHE sont bien présent filtre sur nb_clicks == 0
print("\nÉtudiants qui n'ont jamais ouvert ARCHE (Vérification injection) :")
print(df_final[df_final['nb_clicks'] == 0])

print(f"L'étude va porter sur {len(df_final)} étudiants ")
return df_final

if __name__ == "__main__":
    # Chargement des données brutes
    df_logs_brut, df_notes_brut = charger_donnees()

    # nettoyage des données
    df_logs_clean, df_notes_clean = nettoyage_donnees(df_logs_brut, df_notes_brut)

    # calcule des indicateurs
    resultat = calculer_indicateurs(df_logs_clean, df_notes_clean)

```

### Gestion des erreurs de features.py :



Suppression du fichier notes.csv

Load.py cherche les fichiers et ne les trouve pas il affiche alors le message :

ERREUR : Les fichiers sont introuvables dans le dossier data

Vérifie que tu as bien copié les fichiers dans data

Load.py retourne le couple (None , None ) qui va être envoyé à l'étape suivante

Cleaner.py va recevoir les deux None qui va à son tour renvoyer le message :

il n'est pas possible de nettoyer les données car il y a un souci pour la lecture des fichiers logs.csv et notes.csv

Cleaner.py retourne le couple (None , None ) qui va être envoyé à l'étape suivante

Calculer\_indicateur reçoit ces (None,none), déclenche sa propre sécurité et s'arrête proprement.

```
C:\Users\Etudiant\PycharmProjects\Prediction_reussite\.venv\Scripts\python.exe C:\Users\Etudiant\PycharmProjects\Prediction_reussite\src\features.py
ERREUR : Le fichier des notes est manquant
Vérifie que tu as bien copié les fichiers dans data
il n'est pas possible de nettoyer les données car il y a un souci pour la lecture des fichiers logs.csv et notes.csv

[!] ERREUR (features.py) : Les données nettoyées sont absentes (None).
    -> Le calcul des indicateurs ne peut pas être effectué.

Process finished with exit code 0
```

## **7. Fichier d'exploration des données (exploration.py) :**

Installation du package matplotlib 3.10.8

Le module exploration.py permet de visualiser les données nettoyées pour identifier les tendances majeures de l'activité sur ARCHE. Il quantifie les ressources consultées, dénombre les étudiants actifs et extrait le "Top 5" des actions les plus fréquentes pour comprendre l'usage global de la plateforme. Il permet de lister les étudiants présents dans le fichier des notes mais absents des logs, isolant ainsi ceux n'ayant aucune activité numérique. Le script intègre des affichages de contrôle en console pour visualiser la cohérence des effectifs avant l'étape de modélisation.

### **fichier exploration.py :**

```
import pandas as pd
import matplotlib.pyplot as plt

def exploration_data(df_logs_clean, df_notes_clean):

    # Nombre d'élèves différents
    nb_eleves = df_logs_clean['pseudo'].nunique()
    print(f"Nombre d'étudiants actifs dans les logs : { nb_eleves} ")

    # Nombre de cours différents
    nb_cours = df_logs_clean['contexte'].nunique()
    print(f"Nombre de ressources (cours/chapitres) consultées : { nb_cours} ")

    # Top 5 des activités les plus fréquentes
    print("Top 5 des types d'actions :")
    print(df_logs_clean['evenement'].value_counts().head(5).to_string(name=False, dtype=False))

def voir_les_absents(df_logs_clean, df_notes_clean):
    print("Visualisation des étudiant sans activité sur ARCHE")

    # liste des étudiant qui ont eu au moins une activité
    liste_actifs = list(df_logs_clean['pseudo'].unique())

    # création liste vide de ceux qui n'ont pas utilisé ARCHE
    pseudos_absents = []

    # Pour chaque étudiant présent dans le fichier des notes
    for pseudo_etudiant in df_notes_clean['pseudo'].unique():
        # si l'étudiant n'apparaît pas dans la liste des actifs
        if pseudo_etudiant not in liste_actifs:
            # Alors ajout aux absents
            pseudos_absents.append(pseudo_etudiant)

    # Affichage de ceux qui ne se sont pas connecté sur ARCHE avec leur note respective
    df_resultat = df_notes_clean[df_notes_clean['pseudo'].isin(pseudos_absents)]

    print(f"Voici les { len(df_resultat)} étudiants qui n'ont jamais ouvert ARCHE :")
    print(df_resultat[['pseudo', 'note']])

    print(" 5 premières lignes du tableau de logs nettoyé :")
    print(df_logs_clean.head(5))

    return pseudos_absents
```

```

if __name__ == "__main__":
    from load import charger_donnees
    from cleaner import nettoyage_donnees

    # récupération des données brutes (df_logs, df_notes)
    df_logs, df_notes = charger_donnees()

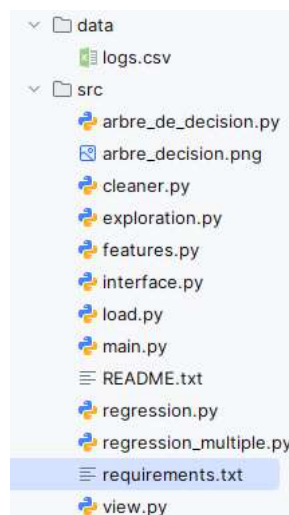
    if df_logs is not None:
        # récupération des données nettoyées (df_logs_clean, df_notes_clean)
        df_logs_clean, df_notes_clean = nettoyage_donnees(df_logs, df_notes)

        # exploration avec les données nettoyées
        exploration_data(df_logs_clean, df_notes_clean)

        # affichage des étudiants qui n'ont pas été sur arche et de leur note
        absents = voir_les_absents(df_logs_clean, df_notes_clean)

```

### Gestion des erreurs de exploration.py :



Lorsque je supprime le fichier notes.csv et que je lance `if __name__ == "__main__":` du module `exploration.py`, le message d'erreur du module `load.py` s'affiche car le script détecte l'absence de la ressource avant de commencer l'analyse

`Exploration.py` appelle la fonction `charger-données()` du module `load.py` celui-ci vérifie physiquement la présence des fichiers via `os.path.exists` qui se trouve dans `load.py`. Ce qui bloque le flux, puisque `notes.csv` est manquant et renvoie la valeur `None`. Le module `exploration.py` ne contient pas de gestion d'erreurs redondante car il bénéficie de la sécurité centralisée du module `load.py`. En cas d'absence des fichiers sources, le module de chargement bloque le flux de données en amont

```

C:\Users\Etudiant\PycharmProjects\Prediction_reussite\.venv\Scripts\python.exe C:\Users\Etudiant\PycharmProjects\Prediction_reussite\src\exploration.py
ERREUR : Le fichier des notes est manquant
Vérifie que tu as bien copié les fichiers dans data

Process finished with exit code 0

```

## **8. Fichier de régression unitaire des données (regression.py) :**

Installation du package scipy 1.17.0

Le module regression.py calcule la régression linéaire simple de chaque indicateur d'activité. Il utilise la bibliothèque SciPy pour déterminer l'équation de la droite de tendance, le coefficient de corrélation et le coefficient de détermination. Ces valeurs permettent d'évaluer la correspondance entre un comportement spécifique et la note finale. Pour assurer la robustesse de l'analyse, le script traite les données nettoyées avant d'afficher les résultats détaillés en console.

### **fichier regression.py :**

```
import pandas as pd
import matplotlib.pyplot as plt
from scipy import stats
from features import calculer_indicateurs

def analyser_regressions(df):
    if df_final is None:
        print(" ARRÊT : Les données sont manquantes. Vérifiez vos fichiers logs.csv ou notes.csv.")
        return # Arrêt propre ici

    print("\n--- ANALYSE PAR RÉGRESSION LINÉAIRE ---")

    # indicateurs à tester
    indicateurs = ['nb_clicks', 'nb_jours', 'nb_composants', 'nb_contextes', 'temps_total_sec', 'nb_tests']

    for col in indicateurs:
        # identification des données
        x = df[col]
        y = df['note']

        # Calcul de la régression
        res = stats.linregress(x, y)

        # Affichage des résultats
        print(f"\nIndicateur : {col}")
        print(f" Coefficient de corrélation (r) : {res.rvalue:.2f}")
        print(f" Coefficient de détermination (r²) : {res.rvalue**2:.2f}")
        print(f" Équation : Note = {res.slope:.2f} * {col} + {res.intercept:.2f}")

    if __name__ == "__main__":
        from load import charger_donnees
        from cleaner import nettoyage_donnees

        # 1. Préparation des données (Chargement -> Nettoyage -> Indicateurs)
        df_logs, df_notes = charger_donnees()
        df_logs_clean, df_notes_clean = nettoyage_donnees(df_logs, df_notes)
        df_final = calculer_indicateurs(df_logs_clean, df_notes_clean)

        # 2. Lancement de la régression
        analyser_regressions(df_final)
```

## Gestion des erreurs de regression.py :



Suppression du fichier notes.csv

Lorsque je supprime le fichier notes.csv et que je lance `if __name__ == "__main__":` du module regression.py.

Load.py retourne le couple (None,None) qui va être envoyé à l'étape suivante

Cleaner.py va recevoir les deux None qui va a son tour renvoyer le message :

il n'est pas possible de nettoyer les données car il y a un souci pour la lecture des fichiers logs.csv et notes.csv

Features.py qui reçoit (None,None) en entrée déclenche alors sa propre sécurité interne. Les données nettoyées sont absentes ce qui affiche un message d'erreur

[!] ERREUR (features.py) : Les données nettoyées sont absentes (None).

-> Le calcul des indicateurs ne peut pas être effectué.

features.py revoie une valeur None unique qui permet dans regression.py d'effectuer un arrêt propre avec la vérification du paramètre d'entrée df.

```
C:\Users\Etudiant\PycharmProjects\Prediction_reussite\.venv\Scripts\python.exe C:\Users\Etudiant\PycharmProjects\Prediction_reussite\src\regression.py
ERREUR : Le fichier des notes est manquant
Vérifie que tu as bien copié les fichiers dans data
il n'est pas possible de nettoyer les données car il y a un souci pour la lecture des fichiers logs.csv et notes.csv

[!] ERREUR (features.py) : Les données nettoyées sont absentes (None).
-> Le calcul des indicateurs ne peut pas être effectué.
ARRÊT : Les données sont manquantes. Vérifiez vos fichiers logs.csv ou notes.csv.

Process finished with exit code 0
```

## 9. Fichier de regression multiple (regression\_multiple.py) :

Installation du package statsmodels 0.14.6

Le module regression\_multiple.py permet de donner les notes en fonction des combinaisons simultanément de l'ensemble des six indicateurs d'activité (clics, temps, jours, outils, contextes et tests). Contrairement à la régression simple, il utilise la bibliothèque statsmodels pour calculer une équation globale permettant de mesurer l'impact relatif de chaque variable tout en neutralisant les autres. Le modèle fournit un coefficient de détermination global qui indique la part de la note finale expliquée par l'activité numérique sur ARCHE. Le script analyse la p-value (F-statistic) : une valeur inférieure à 0,05 confirme que le modèle est statistiquement significatif pour prédire la réussite. Le module prend en compte la cascade de sécurité.

### fichier regression\_multiple.py :

```
import pandas as pd
import statsmodels.formula.api as smf

def analyser_regression_multiple(df):
    if df is None:
        print(" ARRÊT : Les données sont manquantes pour la régression multiple.")
        return

    # régression linéaire multiple
    print(" RÉGRESSION LINÉAIRE MULTIPLE ")

    # Equation régression multiple :
    # Note =  $\beta_0 + (\beta_1 * clics) + (\beta_2 * jours) + (\beta_3 * composants) + (\beta_4 * contextes) + (\beta_5 * temps) + (\beta_6 * nombre\ de\ test)$ 
    formule = "note ~ nb_clics + nb_jours + nb_composants + nb_contextes + temps_total_sec + nb_tests"

    # Calcul des meilleurs coefficients  $\beta$  pour minimiser l'erreur
    modele = smf.ols(formule=formule, data=df).fit()

    # Affichage du résumé statistique
    print(modele.summary())

    # Explication des formules
    print("FORMULES UTILISÉES")
    print(f"1. Modèle :  $Y = X\beta + \epsilon$  (où Y est la note et X les indicateurs)")
    print(f"2. R-squared ( $R^2$ ) : {modele.rsquared:.2f} ")
    print(f" Cela signifie que {modele.rsquared * 100:.0f} % de la note est expliquée par l'activité ARCHE.")

    # Interprétation de la p_value (F-statistic)
    p_value = modele.f_pvalue
    print(f"3. Prob (F-statistic) : {p_value:.4e} ")

    if p_value < 0.05:
        print(f"Comme la p-value ({p_value:.4e}) est inférieure à 0.05,")
        print(" Le modèle global est statistiquement significatif.")
    else:
        print(f"Comme la p-value ({p_value:.4e}) est supérieure à 0.05,")
```



```
print("Le modèle n'est pas considéré comme statistiquement significatif.")
```

```
# Bloc de test
if __name__ == "__main__":
    from load import charger_donnees
    from cleaner import nettoyage_donnees
    from features import calculer_indicateurs
```

### **Gestion des erreurs de regression\_multiple.py :**

Si le fichier notes.csv ou load.csv est manquant, load.py retourne le couple (None, None) qui va être envoyé à l'étape suivante

Cleaner.py va recevoir les deux None qui va à son tour renvoyer le message :

il n'est pas possible de nettoyer les données car il y a un souci pour la lecture des fichiers logs.csv et notes.csv

Features.py qui reçoit (None, None) en entrée déclenche alors sa propre sécurité interne. Les données nettoyées sont absentes ce qui affiche un message d'erreur

[!] ERREUR (features.py) : Les données nettoyées sont absentes (None).

-> Le calcul des indicateurs ne peut pas être effectué.

features.py renvoie une valeur None unique qui permet dans regression.py d'effectuer un arrêt propre avec la vérification du paramètre d'entrée df.

```
C:\Users\Etudiant\PycharmProjects\Prediction_reussite\.venv\Scripts\python.exe C:\Users\Etudiant\PycharmProjects\Prediction_reussite\src\regression_multiple.py
ERREUR : Le fichier des notes est manquant
Vérifie que tu as bien copié les fichiers dans data
il n'est pas possible de nettoyer les données car il y a un souci pour la lecture des fichiers logs.csv et notes.csv

[!] ERREUR (features.py) : Les données nettoyées sont absentes (None).
-> Le calcul des indicateurs ne peut pas être effectué.
ARRÊT : Les données sont manquantes pour la régression multiple.

Process finished with exit code 0
```

## 10. Arbre de décision (arbre de decision.py) :

Installation du package scikit-learn 1.8.0

Le module `arbre_de_decision.py` utilise un classifieur supervisé de la bibliothèque scikit-learn. Pour ce modèle il est nécessaire de transformer les notes en classes binaires (échec (0) ou réussite (1)) pour identifier les profils d'étudiants. La profondeur de l'arbre est limitée à 3 niveaux ce qui permet de visualiser les seuils de décision critiques basés sur les indicateurs d'activité. Le script calcule la métrique d'accuracy (précision globale) pour mesurer l'efficacité du modèle et génère une représentation graphique. Cette méthode permet de capturer des stratégies de réussite plus complexes sur la plateforme ARCHE. Le module prend en compte la cascade de sécurité.

### Fichier arbre de decision.py :

```
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.metrics import accuracy_score

from load import charger_donnees
from cleaner import nettoyage_donnees
from features import calculer_indicateurs

def entrainer_arbre_decision(df):
    if df is None:
        print(" ARRÊT : Les données sont manquantes pour l'arbre de décision.")
        return
    """
    Fonction transforme les notes en classes (0 ou 1)
    et entraîne un arbre de décision pour prédire la réussite.
    """
    print(" ANALYSE PAR ARBRE DE DÉCISION")

    # colonne 'reussite' : 1 si note >= 10, sinon 0
    df_arbre = df.copy()
    # liste vide pour stocker nos 0 et 1
    resultats = []

    # chaque note est transformée une à une
    for note in df_arbre['note']:
        if note >= 10:
            resultats.append(1) # Réussite
        else:
            resultats.append(0) # Échec

    # la liste est ajoutée comme une nouvelle colonne dans le tableau
    df_arbre['reussite'] = resultats

    # selection des paramètres
    indicateurs = ['nb_clicks', 'nb_jours', 'nb_composants', 'nb_contextes', 'temps_total_sec', 'nb_tests']
    X = df_arbre[indicateurs]
    y = df_arbre['reussite']
```

```

# profondeur limité à 3 pour avoir une image lisible
arbre = DecisionTreeClassifier(max_depth=3, random_state=42)
arbre.fit(X, y)

# Evaluation
predictions = arbre.predict(X)
precision = accuracy_score(y, predictions)
print(f"Précision du modèle (Accuracy) : { precision:.2f} ")

# Visualisation de l'arbre
plt.figure(figsize=(15, 8))
plot_tree(arbre,
          feature_names=indicateurs,
          class_names=['Échec', 'Réussite'],
          filled=True,
          rounded=True,
          fontsize=10)
plt.title("Arbre de Décision : Stratégies de réussite sur ARCHE")

# Sauvegarde de l'image
plt.savefig("arbre_decision.png")
print("L'image de l'arbre a été sauvegardée sous 'arbre_decision.png'")

plt.show()

return arbre

if __name__ == "__main__":
    from load import charger_donnees
    from cleaner import nettoyage_donnees
    from features import calculer_indicateurs

    # 1. Préparation des données
    df_logs, df_notes = charger_donnees()
    df_logs_clean, df_notes_clean = nettoyage_donnees(df_logs, df_notes)
    df_final = calculer_indicateurs(df_logs_clean, df_notes_clean)

    # 2. Lancement de l'analyse
    entrainer_arbre_decision(df_final)

```

## Gestion des erreurs de arbre\_de décision.py :

Si le fichier notes.csv ou load.csv est manquant, load.py retourne le couple (None, None) qui va être envoyé à l'étape suivante

Cleaner.py va recevoir les deux None qui va à son tour renvoyer le message :

il n'est pas possible de nettoyer les données car il y a un souci pour la lecture des fichiers logs.csv et notes.csv

Features.py qui reçoit (None, None) en entrée déclenche alors sa propre sécurité interne. Les données nettoyées sont absentes ce qui affiche un message d'erreur

[!] ERREUR (features.py) : Les données nettoyées sont absentes (None).

-> Le calcul des indicateurs ne peut pas être effectué.

features.py renvoie une valeur None unique qui permet dans arbre\_de\_decision.py d'effectuer un arrêt propre avec la vérification du paramètre d'entrée df.

```
C:\Users\Etudiant\PycharmProjects\Prediction_reussite\.venv\Scripts\python.exe C:\Users\Etudiant\PycharmProjects\Prediction_reussite\src\arbre_de_decision.py
ERREUR : Le fichier des notes est manquant
Vérifie que tu as bien copié les fichiers dans data
il n'est pas possible de nettoyer les données car il y a un souci pour la lecture des fichiers logs.csv et notes.csv

[!] ERREUR (features.py) : Les données nettoyées sont absentes (None).
-> Le calcul des indicateurs ne peut pas être effectué.
ARRÊT : Les données sont manquantes pour l'arbre de décision.

Process finished with exit code 0
```

## 11. Interface (interface.py) :

Le module interface.py centralise l'ensemble du projet via une interface graphique développée avec Tkinter. Il orchestre le flux de travail, chaque bouton de l'interface appelle une fonction spécifique issue des modules techniques :

- Analyse des logs de connexion
- Charger & nettoyer les données
- Calculer les indicateurs
- Explorer les données
- Afficher les graphiques
- Lancer les régressions simples
- Lancer la régression multiple
- Arbre de décision

Pour traiter les données les boîtes de dialogue assurent la validation des flux en informant l'utilisateur du succès des opérations ou des erreurs de fichiers. Cette architecture garantit la cohérence de l'analyse en vérifiant que chaque étape critique est validée avant de passer à la suivante.

### Fichier interface.py :

```
import tkinter as tk
from tkinter import messagebox
from load import charger_donnees
from cleaner import nettoyage_donnees
from features import calculer_indicateurs
from regression import analyser_regressions
from regression_multiple import analyser_regression_multiple
from view import afficher_graphiques
from arbre_de_decision import entrainer_arbre_decision
from exploration import exploration_data, voir_les_absents

class ApplicationAnalyse(tk.Tk):
    def __init__(self):
        super().__init__()
        self.title("Prédiction de Réussite - ARCHE")
        self.geometry("450x350")

        # Titre dans la fenêtre
        tk.Label(self, text="Analyse des logs de connexion", font=("Arial", 14, "bold")).pack(pady=10)

        # Bouton 1 : Charger et Nettoyer les données
        tk.Button(self, text="1. Charger & nettoyer les données", command=self.etape_nettoyage, width=35,
            bg="#FFF3E0").pack(pady=5)

        # Bouton 2 : Calculer les indicateurs
        tk.Button(self, text="2. Calculer les indicateurs", command=self.etape_calcul, width=35,
            bg="#F3E5F5").pack(pady=5)

        # Bouton 3 : Exploration des données
        tk.Button(self, text="3. Explorer les données", command=self.etape_exploration,
            width=35, bg="#E0F2F1").pack(pady=5)

        # Bouton 4 : Voir les Graphiques
        tk.Button(self, text="4. Afficher les graphiques", command=self.etape_visu, width=35,
            bg="#D1E8FF").pack(pady=5)
```

```

# Bouton 5 : Régression simple
tk.Button(self, text="5. Lancer les régressions simples", command=self.etape_stats, width=35,
bg="#D1FFD1").pack(pady=5)

# Bouton 6 : Régression Multiple
tk.Button(self, text="6. Lancer la régression multiple", command=self.etape_stats_multiple, width=35,
bg="#FFFD1").pack(pady=5)

# BOUTON 7 : Arbre de décision
tk.Button(self, text="7. Arbre de décision ", command=self.etape_arbre, width=35, bg="#D1C4E9").pack(pady=5)

# Variables pour stocker les données entre les étapes
self.df_final = None

def etape_nettoyage(self):
    # On récupère les données brutes (df_logs, df_notes)
    df_logs, df_notes = charger_donnees()

    if df_logs is not None:
        # On stocke les données nettoyées dans l'application (self.df_logs_clean, self.df_notes_clean)
        self.df_logs_clean, self.df_notes_clean = nettoyage_donnees(df_logs, df_notes)
        messagebox.showinfo("Succès", "Données chargées et nettoyées !")
    else:
        messagebox.showerror("Erreur", "Fichiers introuvables.")

def etape_exploration(self):
    # Vérification que les données nettoyées existent
    if hasattr(self, 'df_logs_clean'):
        print("\n--- EXPLORATION DES DONNÉES ---")
        exploration_data(self.df_logs_clean, self.df_notes_clean)
        voir_les_absents(self.df_logs_clean, self.df_notes_clean)
        messagebox.showinfo("Exploration", "L'exploration a été affichée dans la console.")
    else:
        messagebox.showwarning("Attention", "Veuillez d'abord charger et nettoyer les données.")

def etape_calcul(self):
    # Utilisation des noms complets pour le calcul des indicateurs
    if hasattr(self, 'df_logs_clean'):
        self.df_final = calculer_indicateurs(self.df_logs_clean, self.df_notes_clean)
        messagebox.showinfo("Succès", f"Indicateurs calculés pour {len(self.df_final)} étudiants.")
    else:
        messagebox.showwarning("Attention", "Veuillez d'abord charger les données.")

def etape_visu(self):
    if self.df_final is not None:
        afficher_graphiques(self.df_final)
    else:
        messagebox.showwarning("Attention", "Calculs non effectués.")

def etape_stats(self):
    if self.df_final is not None:
        analyser_regressions(self.df_final)
        messagebox.showinfo("Analyse", "Résultats régressions simples générées dans la console.")
    else:
        messagebox.showwarning("Attention", "Données non prêtes.")

def etape_stats_multiple(self):
    if self.df_final is not None:
        analyser_regression_multiple(self.df_final)
        messagebox.showinfo("Analyse Multiple", "Résultat régression multiple généré dans la console.")

```

```

else:
    messagebox.showwarning("Attention", "Données non prêtes.")

def etape_arbre(self):
    if self.df_final is not None:
        entrainer_arbre_decision(self.df_final)
        messagebox.showinfo("Arbre", "L'Arbre de Décision a été généré avec succès !")
    else:
        messagebox.showwarning("Attention", "Données non prêtes.")

if __name__ == "__main__":
    app = ApplicationAnalyse()
    app.mainloop()

```

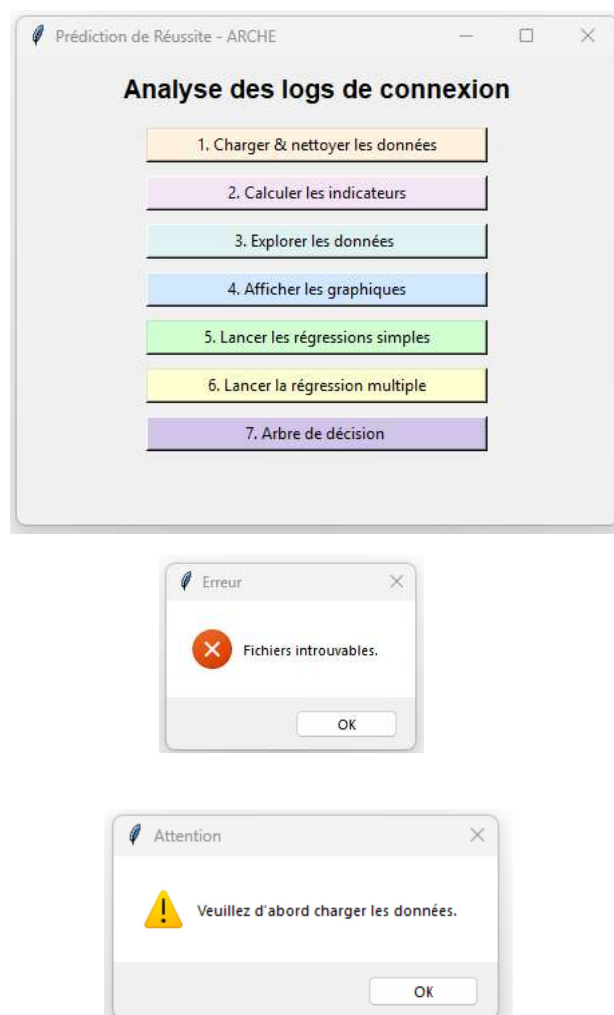
### Gestion des erreurs de interface.py:





Contrairement aux scripts de console qui s'arrêtent, l'interface reste ouverte mais bloque les actions incorrectes :

Chaque bouton est protégé par une "garde" qui vérifie l'existence des données dans l'objet self avant de solliciter les modules externes.

L'arrêt propre est ici remplacé par une interdiction d'agir.

Test absence du fichier notes.csv







## 12. Interface (main.py) :

Le module main.py sert de point d'entrée unique pour l'exécution de l'ensemble du projet. Il importe la classe ApplicationAnalyse depuis le module d'interface pour instancier l'application graphique. Sa fonction principale consiste à lancer la boucle mainloop qui maintient la fenêtre de prédiction active pour l'utilisateur. Le script intègre des messages de suivi en console pour confirmer le démarrage et la fermeture propre de l'application. Cette structure permet d'isoler le lancement du logiciel de sa logique interne de calcul.

### Fichier main.py :

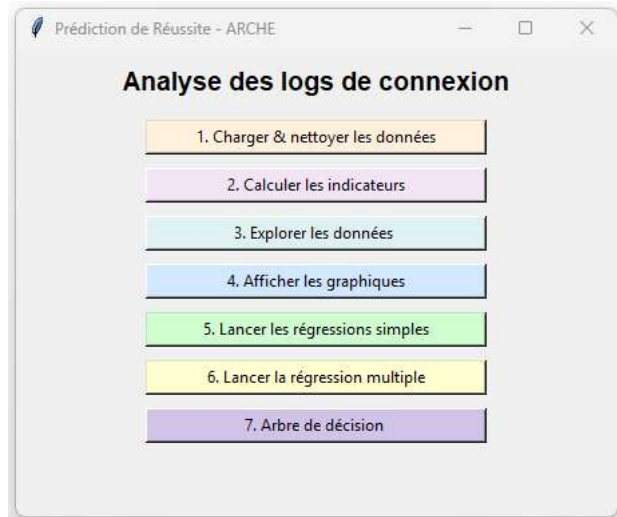
```
# Importation de la classe ApplicationAnalyse depuis ton fichier interface.py  
from interface import ApplicationAnalyse
```

```
def main():  
    # Création de l'objet mon_interface  
    mon_interface = ApplicationAnalyse()  
  
    # Lancement de la boucle de l'application  
    print("=== L'INTERFACE DE PRÉDICTION EST PRÊTE ===")  
    mon_interface.mainloop()  
  
    # Message affiché une fois que l'utilisateur ferme la fenêtre  
    print("=== FERMETURE DE L'APPLICATION ===")  
  
if __name__ == "__main__":  
    # Appel de la fonction principale pour démarrer le projet  
    main()
```

### Gestion des erreurs de main.py:

Le programme main.py instancie la classe ApplicationAnalyse et lance la boucle mainloop() . À cette étape aucune donnée n'est encore lue sur le disque dur.

Le programme se contente de dessiner la fenêtre et d'attendre que l'utilisateur clique sur un bouton.

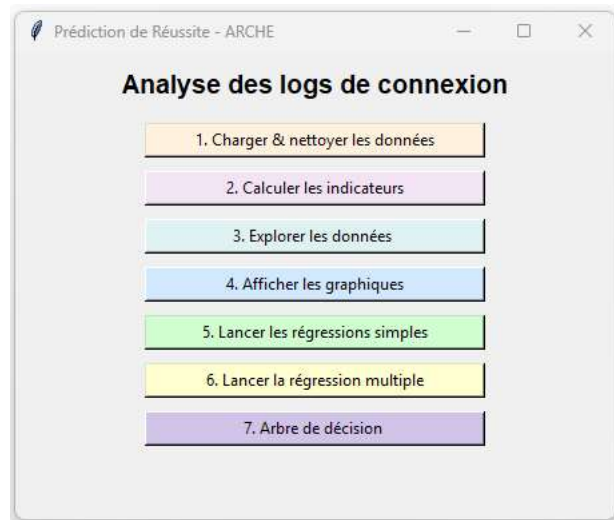


Et d'afficher le message :

=== L'INTERFACE DE PRÉDICTION EST PRÊTE ===

### 13. Conclusion :


Lancement de l'application via le main :



```
=== L'INTERFACE DE PRÉDICTION EST PRÊTE ===  
les données ont été chargées avec succès!  
Fichier logs :16227 lignes lues  
Fichier notes :99 lignes lues  
le nombre de doublon dans notes.csv est de 0  
il n'y a donc pas de doublon  
Toutes les dates ont été converties correctement  
Comparaison avant nettoyage  
Étudiants dans le fichier NOTES : 99  
Étudiants dans le fichier LOGS : 109  
Comparaison après nettoyage  
Étudiants dans le fichier NOTES : 99  
Étudiants dans le fichier LOGS : 95
```

On constate que dans le fichier des notes nous avons 99 étudiants, dans le fichier des logs nous avons plus d'étudiant 109 cet écart est du à 10 personnes en dehors de la promotion qui se sont connectées.

Une fois le nettoyage de ces 10 personnes en dehors de la promotion réalisé, on constate qu'il y a un écart de 4 étudiant entre le fichier notes et le fichier logs, ceci est du au fait que ces 4 étudiants ne se sont pas connectés sur ARCHE.



### Aperçu des 5 premières ligne du tableau :


```
Aperçu des 5 premières lignes :
pseudo  note  nb_clics  ...  nb_contextes  temps_total_sec  nb_tests
0       318 11.050    35.0  ...           12.0           1539.0      17.0
1       717 11.506    383.0 ...           73.0           9008.0     167.0
2       364 10.022    504.0 ...           62.0          11821.0     294.0
3        93 12.160    167.0 ...           25.0           2963.0     102.0
4       543  9.886    205.0 ...           44.0           3013.0     101.0
```

### Ainsi que des étudiants qui n'ont pas ouvert ARCHE :

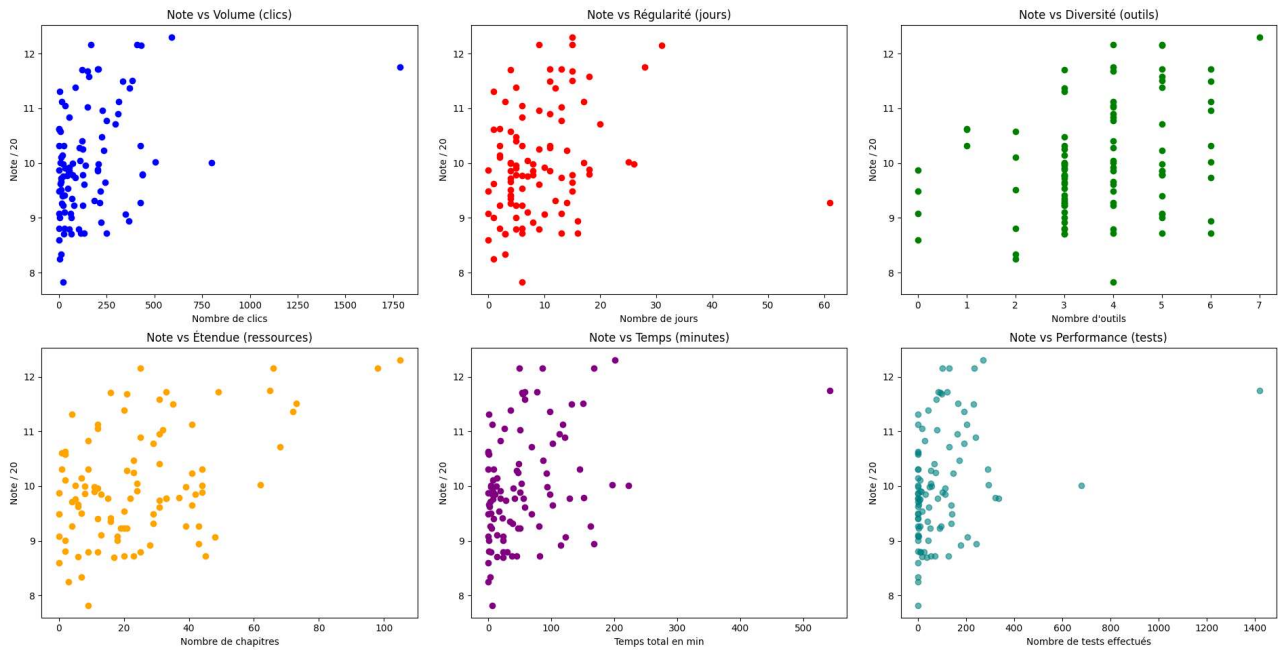
Un facteur de zéro est attribué pour les paramètres de suivi

On remarque que les 4 étudiants qui n'ont pas ouvert ARCHE ont tous des notes inférieures à 10

```
Étudiants qui n'ont jamais ouvert ARCHE (Vérification injection) :
pseudo  note  nb_clics  ...  nb_contextes  temps_total_sec  nb_tests
14       312 9.078      0.0  ...           0.0            0.0        0.0
30       127 8.600      0.0  ...           0.0            0.0        0.0
47       990 9.873      0.0  ...           0.0            0.0        0.0
52       790 9.487      0.0  ...           0.0            0.0        0.0
```



```
--- EXPLORATION DES DONNÉES ---
Nombre d'étudiants actifs dans les logs : 95
Nombre de ressources (cours/chapitres) consultées : 106
Top 5 des types d'actions :
evenement
Module de cours consulté           4295
Cours consulté                     2924
Tentative de test relue             1433
Tentative de test consultée         1296
Résumé de tentative de test consulté 1169
Visaualisation des étudiant sans activité sur ARCHE
Voici les 4 étudiants qui n'ont jamais ouvert ARCHE :
pseudo  note
14       312 9.078
30       127 8.600
47       990 9.873
52       790 9.487
```



Visuellement on peut déduire que plus on se déplace vers la droite (plus on s'investit), plus les points ont tendance à monter (meilleure note).

### Régression simples :

#### --- ANALYSE PAR RÉGRESSION LINÉAIRE ---

Indicateur : nb\_clics

Coefficient de corrélation (r) : 0.36

Coefficient de détermination ( $r^2$ ) : 0.13

Équation :  $\text{Note} = 0.00 * \text{nb\_clics} + 9.74$

Indicateur : nb\_jours

Coefficient de corrélation (r) : 0.24

Coefficient de détermination ( $r^2$ ) : 0.06

Équation :  $\text{Note} = 0.03 * \text{nb\_jours} + 9.74$

Indicateur : nb\_composants

Coefficient de corrélation (r) : 0.32

Coefficient de détermination ( $r^2$ ) : 0.10

Équation :  $\text{Note} = 0.22 * \text{nb\_composants} + 9.19$

Indicateur : nb\_contextes

Coefficient de corrélation (r) : 0.46

Coefficient de détermination (r<sup>2</sup>) : 0.21

Équation : Note = 0.02 \* nb\_contextes + 9.47

Indicateur : temps\_total\_sec

Coefficient de corrélation (r) : 0.36

Coefficient de détermination (r<sup>2</sup>) : 0.13

Équation : Note = 0.00 \* temps\_total\_sec + 9.72

Indicateur : nb\_tests

Coefficient de corrélation (r) : 0.32

Coefficient de détermination (r<sup>2</sup>) : 0.10

Équation : Note = 0.00 \* nb\_tests + 9.83

Chaque facteur séparément ne permet pas d'expliquer la note obtenue, la régression de chaque paramètre unitairement donne de faible fiabilité (r<sup>2</sup>) la plus importante atteint 0,21. C'est pour cette raison que je vais faire une régression multiple.

## Régression multiple :

OLS Regression Results						
=====						
Dep. Variable:	note	R-squared:	0.230			
Model:	OLS	Adj. R-squared:	0.179			
Method:	Least Squares	F-statistic:	4.570			
Date:	Sun, 15 Feb 2026	Prob (F-statistic):	0.000421			
Time:	12:24:12	Log-Likelihood:	-127.05			
No. Observations:	99	AIC:	268.1			
Df Residuals:	92	BIC:	286.3			
Df Model:	6					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]
-----						
Intercept	9.4004	0.264	35.657	0.000	8.877	9.924
nb_clicks	0.0012	0.005	0.257	0.797	-0.008	0.010
nb_jours	-0.0180	0.025	-0.723	0.472	-0.068	0.032
nb_composants	0.0524	0.088	0.599	0.551	-0.122	0.226
nb_contextes	0.0209	0.011	1.975	0.051	-0.000	0.042
temps_total_sec	-4.582e-05	0.000	-0.437	0.663	-0.000	0.000
nb_tests	0.0003	0.004	0.069	0.945	-0.008	0.009
=====						
Omnibus:	2.477	Durbin-Watson:	1.869			
Prob(Omnibus):	0.290	Jarque-Bera (JB):	2.111			
Skew:	0.238	Prob(JB):	0.348			
Kurtosis:	2.466	Cond. No.	1.65e+04			
=====						

### Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

[2] The condition number is large, 1.65e+04. This might indicate that there are strong multicollinearity or other numerical problems.

### FORMULES UTILISÉES

1. Modèle :  $Y = X\beta + \varepsilon$  (où Y est la note et X les indicateurs)

2. R-squared ( $R^2$ ) : 0.23

Cela signifie que 23% de la note est expliquée par l'activité ARCHE.

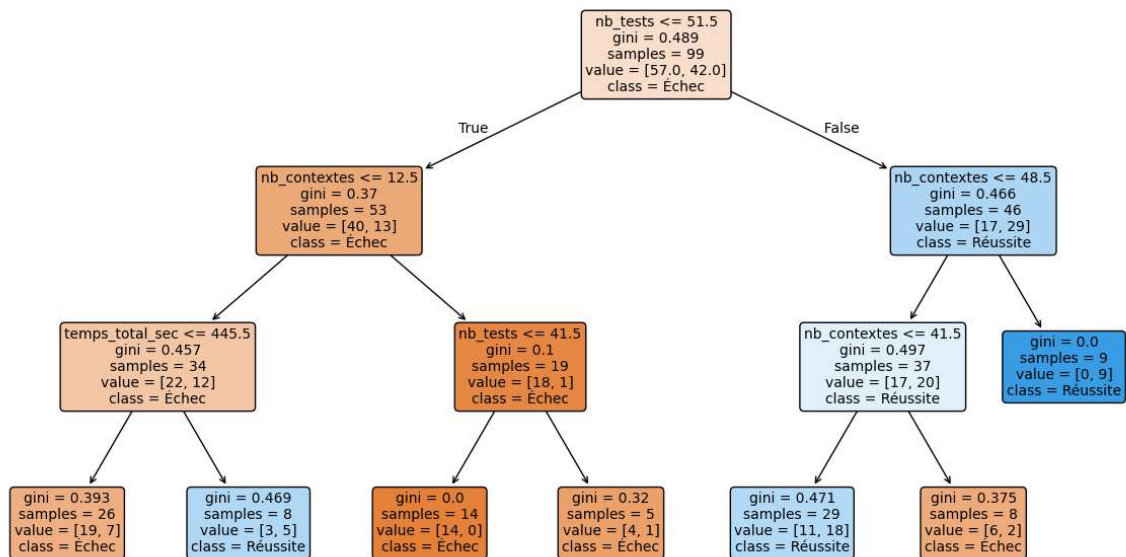
3. Prob (F-statistic) : 4.2111e-04

Comme la p-value (4.2111e-04) est inférieure à 0.05,  
le modèle global est statistiquement significatif.

La régression multiple de l'ensemble des paramètres donne également un coefficient de détermination ( $r^2$ ) de 0,23 qui est relativement faible.

## Arbre de décision :

Arbre de Décision : Stratégies de réussite sur ARCHE



L'arbre de décision permet de déterminer les meilleures conditions qui permettent d'obtenir le diplôme ces conditions sont les suivantes :

- Faire un nombre de test supérieur à 52
- Voir un nombre de contexte supérieur à 49

Ce devoir m'aura permis de mettre en place une application et de pouvoir sélectionner le meilleur modèle qui dans ce cas précis et l'arbre de décision.